Proposta de Trabalho — Engenharia de Contexto para RAG sobre Dados Tabulares

Motivação e problema

Modelos de linguagem (LLMs) têm sido cada vez mais usados como interface para responder perguntas sobre documentos que combinam texto e tabelas — um cenário comum em relatórios financeiros, mas também em laudos técnicos, planilhas de negócio e documentação corporativa em geral. A forma como esses dados tabulares são apresentados ao modelo — como texto puro, como Markdown, como JSON, ou de forma seletiva — não é um detalhe trivial de implementação: ela afeta diretamente tanto a precisão das respostas quanto o custo computacional (em tokens) de cada consulta. A literatura de Retrieval-Augmented Generation (RAG) é extensa, mas majoritariamente voltada para texto não-estruturado (parágrafos, documentos); a representação de contexto tabular ainda é pouco sistematizada, especialmente sob a ótica do trade-off entre acurácia e custo.

Objetivo

Este trabalho investiga como diferentes estratégias de representação de contexto tabular afetam a precisão de modelos de linguagem em tarefas de resposta a perguntas sobre relatórios financeiros, e qual o custo em tokens associado a cada estratégia. O objetivo não é apenas medir "qual representação é melhor", mas caracterizar em que condições (tamanho da tabela, complexidade do raciocínio exigido) cada estratégia se torna preferível — ou seja, mapear um trade-off entre qualidade da resposta e custo de processamento, e não apenas reportar um vencedor único.

Contribuição e diferencial

Diferente de abordagens que comparam arquiteturas inteiras de RAG (recuperação de documentos, re-ranking, geração), este trabalho isola uma variável específica e pouco explorada: **a forma de serialização da tabela no prompt**. Comparamos quatro representações — tabela completa em Markdown, tabela completa em JSON, uma abordagem seletiva que recupera apenas as linhas relevantes à pergunta (schema + linhas), e uma tabela bruta linearizada como controle — mantendo fixos o modelo, o texto ao redor e a pergunta. Essa isolação de variável, combinada com uma métrica objetiva (correspondência numérica exata, sem ambiguidade de julgamento subjetivo) e com a quebra dos resultados por complexidade do raciocínio aritmético exigido, é o que diferencia este trabalho de comparações mais amplas e menos controladas já publicadas na área.

Metodologia

Utilizamos o **FinQA**, benchmark público de perguntas e respostas sobre relatórios financeiros reais (10-K/10-Q de empresas do S&P 500), que fornece, para cada pergunta, o texto ao redor, a tabela original e a sequência de operações aritméticas necessárias para chegar à resposta — o que permite classificar automaticamente cada pergunta como extração simples ou raciocínio composto. Testamos três modelos de linguagem open-source de portes distintos (Llama 3.1 8B, Qwen3-8B e Phi-4-mini), executados em ambiente Google Colab, sob as quatro representações de tabela descritas acima. Para cada

combinação de modelo, representação e pergunta, medimos: (i) acurácia numérica, com tolerância de arredondamento; (ii) número de tokens consumidos no prompt e na resposta; e (iii) o cruzamento dessas duas métricas com o tamanho da tabela e a complexidade do raciocínio exigido.

Resultado esperado

Espera-se produzir uma caracterização empírica de quando vale a pena investir em uma representação mais elaborada (como a seleção de linhas relevantes) em vez de simplesmente enviar a tabela inteira — e se essa resposta muda conforme o tamanho do modelo e a complexidade da pergunta. O resultado final é uma curva de custo-benefício (acurácia vs. tokens) que pode orientar decisões práticas de engenharia de contexto em aplicações reais de RAG sobre dados estruturados.