Related Work — RAG Tabular e QA Financeiro

Oct 25, 2026 · @Johnattan

1. Introdução

Responder perguntas numéricas sobre relatórios financeiros exige que o modelo localize valores em tabelas e texto e encadeie cálculos sobre eles. Em sistemas baseados em LLMs, a tabela chega ao modelo como texto, e a forma dessa conversão é uma decisão de engenharia de contexto. Este trabalho investiga como essa decisão afeta a acurácia e o custo em tokens de modelos abertos de cerca de 8B parâmetros no FinQA.

Os 15 trabalhos analisados se organizam em três linhas que raramente se cruzam. A primeira define a tarefa: benchmarks de QA financeiro híbrido (FinQA, TAT-QA, MultiHiertt). A segunda estuda como modelos raciocinam sobre essa tarefa, por prompting ou ajuste fino (Srivastava et al., TAT-LLM). A terceira estuda a representação da tabela fora do domínio financeiro: formato (Sui et al., Singha et al., Min et al.), custo em tokens (TOON, JTON), seleção e recuperação de evidências (Dater, TAP4LLM, TableRAG) e uso do contexto (Lost in the Middle).

O survey de Lu et al. (2025) organiza o campo em representação, treinamento e prompting e serve de mapa para essas linhas. O argumento desta seção é que a terceira linha nunca foi testada nas condições da primeira, e que esse cruzamento é justamente onde se concentram os erros relatados pelos próprios benchmarks.

2. Benchmarks de QA financeiro híbrido

Três benchmarks definem a tarefa e mostram onde os modelos falham. O FinQA (Chen et al., 2021) reúne 8.281 perguntas escritas por especialistas sobre relatórios do S&P 500, cada uma com um programa de cálculo executável. O TAT-QA (Zhu et al., 2021) traz 16.552 perguntas em que tabela e parágrafos se complementam e anota a escala das respostas. O MultiHiertt (Zhao et al., 2022) estende a tarefa para documentos com média de 3,89 tabelas hierárquicas.

Os três propõem modelos de base que seguem o mesmo esquema: recuperar ou marcar evidências e depois gerar um programa ou aplicar um operador. O FinQANet chega a 61,24% de acurácia de execução, contra 91,16% de especialistas. O TagOp chega a 58,0 de F1, contra 90,8 de humanos. No MultiHiertt, o MT2Net fica em 38,43 de F1, contra 87,03.

Além da distância para humanos, os três convergem em dois achados. A acurácia cai com o número de passos: no FinQA, de 67,61% (um passo) para 22,78% (três ou mais); no MultiHiertt, de 43,62 para 15,14 de EM. E a maior parte dos erros está em achar a evidência, não em calcular: 84% no TAT-QA (evidência errada ou faltante) e 64% no MultiHiertt (operando errado ou faltante).

Um terceiro achado aparece de forma indireta. No MultiHiertt, TagOp e FinQANet linearizam a tabela por linha e perdem a hierarquia de cabeçalhos. O MT2Net transforma cada célula em uma frase com todos os seus cabeçalhos e supera o FinQANet (38,43 contra 33,60 de F1) com o mesmo retriever. Os autores atribuem parte do ganho a essa forma de serializar, embora ela venha junto com um sub-módulo novo de trechos.

Esses trabalhos têm limites claros para o nosso problema. Os modelos são encoders treinados anteriores aos LLMs, a serialização é fixa (no FinQA, um template transforma cada linha em frase) e nenhum mede o custo da entrada. As tabelas do FinQA são pequenas, com média de 6,36 linhas e 59 tokens, contra 628 tokens de texto ao redor.

3. LLMs na tarefa: prompting e ajuste fino

Dois trabalhos levam esses benchmarks para a era dos LLMs por caminhos opostos. Srivastava et al. (2024) avaliam seis LLMs em FinQA, TAT-QA, ConvFinQA e MultiHiertt com cinco estratégias de prompting e propõem o EEDP, um prompt que pede para trazer o conhecimento do domínio, extrair a evidência, decompor em operações e responder. Com GPT-4, o EEDP chega a 76,05% no FinQA e 70,32% no MultiHiertt, perto ou acima do Program-of-Thought (75,26% e 67,23%).

O estudo também mostra o desempenho de modelos abertos menores. No FinQA, o Mistral-7B atinge 34,86% e o Llama 2-13B 30,47%, menos da metade do GPT-4 no mesmo prompt. A análise de erros repete o padrão dos benchmarks: no MultiHiertt, 52% dos erros são de extração. O artigo, porém, mantém a tabela em um único formato e não mede tokens.

Um resultado do estudo conecta esta linha à de seleção de evidências. A estratégia Decomposers é a do Dater (Ye et al., 2023), que poda a tabela para uma subtabela antes de responder. Nos dados financeiros, ela foi a pior estratégia nos quatro datasets com GPT-4 e com GPT-3.5 (44,93% no FinQA com GPT-4), e os autores atribuem a queda à perda de informação na poda.

O TAT-LLM (Zhu et al., 2024) segue o caminho do ajuste fino. Ele treina o LLaMA 2 com LoRA para responder em três passos (extrair, raciocinar e executar), com a tabela sempre em Markdown, e recalcula a equação com um executor em código. A versão de 7B chega a 64,60% no FinQA, contra 63,91% do GPT-4 sem exemplos, e a de 70B a 76,81%.

A ablação do TAT-LLM mostra que, em modelos pequenos, o cálculo também pesa: sem o executor externo, o modelo de 7B perde 16,66 pontos no FinQA. Mesmo assim, 71% dos erros restantes são de extração. A comparação com o GPT-4 é desigual, pois um modelo é ajustado nos próprios dados e o outro roda sem exemplos.

Juntos, os dois trabalhos mostram que um modelo de 7B só com prompt fica perto de 35% no FinQA, e ajustado chega a 65%. Nenhum dos dois pergunta quanto dessa diferença poderia ser reduzida mudando apenas a forma de apresentar a tabela, sem treinar o modelo.

4. Representação e recuperação de tabelas

4.1 Formato: o efeito existe, mas a direção muda

Três estudos mostram que o formato da tabela no prompt altera o resultado. Sui et al. (2024) comparam cinco formatos em sete tarefas de estrutura com GPT-3.5 e GPT-4: o HTML lidera (62,43 de média) e o Markdown fica em último (54,71). Eles também mostram que variáveis fora do formato pesam muito: pergunta depois da tabela custa 6,81% e retirar o exemplo do prompt custa 30,38%.

Singha et al. (2023) comparam oito formatos no GPT-3 e chegam a outro ranking: código pandas (79,79) e JSON (77,93) à frente, HTML (71,40) no meio e Markdown (67,32) em último. Min et al. (2024), em QA sobre documentos técnicos com RAG, encontram diferenças de até 9% (avaliação humana) e 16% (GPT-4) entre métodos de conversão, com o Markdown competitivo.

Os três concordam que o formato importa e discordam sobre qual é o melhor. A divergência acompanha diferenças de tarefa (estrutura, busca de fatos, resposta longa), de dados (Wikipedia, Kaggle, documentação de TIC) e de modelo (GPT-3 a GPT-4, Llama-2). Nenhum usa perguntas numéricas de vários passos, domínio financeiro ou modelos abertos recentes de cerca de 8B.

4.2 Custo: formatos compactos e o problema das tabelas pequenas

Outra linha trata o formato como custo. O TOON (Ahaidous et al., 2026) escreve os nomes das colunas uma vez só e reduz em média 39,6% dos tokens em relação ao JSON, com ordem de eficiência estável em sete tokenizadores, incluindo Llama 3.1, Qwen 2.5 e Phi-3. Ele reporta 73,9% de acurácia contra 69,7% do JSON, mas o ganho vem em boa parte de um modelo (Gemini, +10,6 pontos) e não tem teste estatístico.

O JTON (Nandakishore, 2026) segue a mesma ideia mantendo compatibilidade com JSON e economiza em média 28,5% dos tokens, com acurácia praticamente igual (+0,3 ponto, 35 perguntas por modelo). Os dois trabalhos medem acurácia e tokens juntos, mas em

perguntas simples de busca, contagem e filtro sobre dados em grande parte sintéticos.

A economia depende do tamanho e da regularidade da tabela. No TOON, ela chega a 59–61% em dados totalmente tabulares e cai para 15% em dados semiuniformes; no JTON, fica perto de 15% com cinco linhas. Nenhum dos dois testa tabelas do tamanho das do FinQA, imersas em texto. Há ainda ressalvas de autoria: o criador do TOON é coautor do artigo, e o JTON é um preprint de autor único.

4.3 Seleção e recuperação: ganhos fora das finanças, sem isolar a causa

Uma terceira linha reduz a tabela ao que é relevante para a pergunta. O Dater (Ye et al., 2023) usa o LLM para escolher uma subtabela e decompor a pergunta com apoio de SQL, subindo de 72,6% para 85,6% no TabFact e de 47,6% para 65,9% no WikiTableQuestions. O TAP4LLM (Sui et al., 2024) organiza o pré-processamento em seleção, enriquecimento e empacotamento com orçamento de tokens; a seleção híbrida leva o TabFact de 56,20% para 61,37%.

O TableRAG (Chen et al., 2024) recupera esquema e células para guiar um agente que consulta a tabela por código, com ganhos de 6,1 e 5,2 pontos sobre usar só o esquema. Porém, mira tabelas com dezenas de milhares de linhas, ordens de grandeza acima das do FinQA.

Esses ganhos não isolam o efeito de enviar menos linhas. No Dater, retirar só a decomposição de evidências custa 2,0 pontos no WikiTableQuestions, enquanto retirar a decomposição da pergunta custa 4,5. O TAP4LLM mistura seleção, enriquecimento e formato, e o TableRAG tem acesso programático à tabela inteira. Nenhum dos três avalia QA financeiro, e o Dater, quando avaliado em finanças por Srivastava et al., foi a pior estratégia.

4.4 Uso do contexto

Lost in the Middle (Liu et al., 2024) mostra que ter a evidência no contexto não garante usá-la. Em QA com vários documentos, o desempenho tem forma de U: é maior quando a evidência está no início ou no fim e menor no meio. Em algumas posições intermediárias, o GPT-3.5 fica abaixo dos 56,1% que obtém sem documento nenhum.

O resultado dá uma razão para esperar que menos contexto ajude, mas vem de texto e pares chave-valor, não de tabelas. No FinQA há um indício na mesma direção, com modelos treinados: o Longformer lendo a página inteira fica em 21,90%, contra 61,24% do pipeline que recupera três fatos, e fornecer os fatos corretos sobe o resultado para 70,00%. As arquiteturas, porém, são diferentes, então o efeito do tamanho do contexto não está isolado.

5. Análise comparativa

Nenhum dos trabalhos analisados reúne, ao mesmo tempo, QA numérico financeiro, variação controlada do formato da tabela, medição de tokens e modelos abertos de cerca de 8B. A matriz abaixo mostra que quem tem o domínio não varia o formato, e quem varia o formato não tem o domínio.

Trabalho	Domínio financeiro	QA numérico em vários passos	Varia o formato	Seleção de evidência	Mede tokens	LLMs abertos ~8B
FinQA (2021)	✓	✓	✗	◐	✗	✗
TAT-QA (2021)	✓	✓	✗	◐	✗	✗
MultiHiertt (2022)	✓	✓	◐	◐	✗	✗
Srivastava et al. (2024)	✓	✓	✗	◐	✗	◐
TAT-LLM (2024)	✓	✓	✗	✗	✗	◐
Sui et al. (2024)	✗	✗	✓	✗	✗	✗
Singha et al. (2023)	✗	✗	✓	✗	◐	✗
Min et al. (2024)	✗	✗	✓	✗	✗	◐
TOON (2026)	✗	✗	✓	✗	✓	✗
JTON (2026)	◐	✗	✓	✗	✓	◐
Dater (2023)	✗	◐	✗	✓	✗	✗
TAP4LLM (2024)	✗	✗	◐	✓	◐	✗
TableRAG (2024)	✗	◐	✗	✓	◐	◐
Lost in the Middle (2024)	✗	✗	✗	✗	◐	◐
Proposta	✓	✓	✓	✓	✓	✓

✓ coberto de forma central · ◐ parcial · ✗ não coberto. Parciais: MultiHiertt compara linha e célula entre modelos diferentes; FinQA, TAT-QA e MultiHiertt têm retriever acoplado ao modelo treinado; Srivastava et al. usam Mistral-7B e Llama 2-13B, e o TAT-LLM, LLaMA 2 7B ajustado; o JTON tem um conjunto financeiro gerado pelo autor e testa Llama 3.1 8B com 35 perguntas; TAP4LLM controla orçamento de tokens; TableRAG e Lost in the Middle analisam tamanho do contexto. O survey de Lu et al. (2025) não entra na matriz por não ser experimental.

Lidos em conjunto, os trabalhos convergem em quatro pontos:

1. O formato da tabela altera o resultado (Sui, Singha, Min) e nenhum formato vence em todas as tarefas (Singha).
2. O efeito depende do modelo: o ganho do TOON sobre o JSON varia de +1,9 a +10,6 pontos conforme o LLM.
3. Nos benchmarks financeiros, a extração da evidência é a principal fonte de erro (84% no TAT-QA, 64% no MultiHiertt, 71% no TAT-LLM).
4. A acurácia cai com o número de passos (FinQA, MultiHiertt, Srivastava et al.).

E se contradizem em três:

1. Markdown é o pior formato em Sui e Singha, mas competitivo em Min.
2. HTML lidera em Sui e fica no meio em Singha.
3. Selecionar a parte relevante da tabela ajuda no domínio geral (Dater, TAP4LLM, TableRAG), mas a mesma estratégia do Dater foi a pior nos dados financeiros (Srivastava et al.).

As contradições não são ruído a descartar: elas indicam que o melhor formato e o valor da seleção dependem de tarefa, dados e modelo, e por isso precisam ser medidos no cenário de interesse.

6. Lacunas e oportunidades

A análise aponta cinco lacunas. Cada uma se apoia em resultados reportados pelos trabalhos, e não apenas na ausência de um experimento.

L1. O formato nunca foi variado na tarefa em que a extração mais falha. Os cinco trabalhos financeiros fixam a serialização: template por linha no FinQA, linha achatada no TagOp, Markdown no TAT-LLM, formato único em Srivastava et al. Ao mesmo tempo, extração é a maior fonte de erro nesses benchmarks (84%, 64% e 71%), e o MultiHiertt sugere que a forma de serializar pesa mesmo em modelos treinados. A variável mais ligada ao erro dominante está sem estudo controlado no domínio.

L2. Os rankings de formato não se transferem para modelos abertos pequenos. Sui, Singha e Min chegam a rankings contraditórios usando GPT-3 a GPT-4 ou Llama-2, e o TOON usa quatro modelos de API. Modelos abertos de 7–13B são justamente os mais fracos na tarefa (Mistral-7B a 34,86% no FinQA contra 76,05% do GPT-4) e os mais viáveis para dados financeiros sensíveis, motivação do próprio TAT-LLM. O único modelo de ~8B testado com formatos alternativos é o Llama 3.1 8B do JTON, com 35 perguntas simples.

L3. Selecionar linhas ajuda no domínio geral e prejudica no financeiro, sem teste isolado. Dater, TAP4LLM e TableRAG relatam ganhos de 5 a 18 pontos em TabFact, WikiTableQuestions e tabelas grandes. Nos dados financeiros, a poda do Dater foi a pior

estratégia (Srivastava et al.), e o FinQA mostra que entregar os fatos certos sobe a acurácia de 61,24% para 70,00%. Nos três sistemas a seleção vem misturada com decomposição, enriquecimento ou acesso por código, então ninguém mediu o efeito de selecionar linhas com o formato fixo, em perguntas numéricas.

L4. Acurácia e custo não são medidos juntos em perguntas numéricas. Os benchmarks financeiros e os estudos de formato de Sui, Singha e Min não reportam tokens. TOON e JTON reportam os dois, mas em buscas simples e com economia que cai para cerca de 15% em tabelas pequenas ou irregulares. No FinQA, a tabela média tem 59 tokens dentro de um contexto de cerca de 690, então não se sabe se a escolha do formato muda o custo de forma relevante. TAP4LLM e TableRAG alertam ainda que a seleção tem custo próprio, que raramente entra na conta.

L5. O efeito do formato não é cruzado com a complexidade da pergunta. A queda com o número de passos está bem documentada (FinQA, MultiHiertt, Srivastava et al.), assim como a dificuldade das perguntas que exigem tabela e texto (43,80% no FinQA). Nenhum estudo de formato separa os resultados por número de passos ou pela origem da evidência, de modo que não se sabe se um formato ajuda nas perguntas fáceis e atrapalha nas difíceis.

Essas lacunas definem uma oportunidade específica: medir, de forma controlada, como a representação da tabela afeta acurácia e custo de modelos abertos pequenos no QA numérico financeiro. Responder a isso não exige uma arquitetura nova, e sim um desenho experimental que isole a variável que os trabalhos anteriores deixaram fixa ou misturada a outras.

7. Proposta

Propomos um estudo controlado da representação de tabelas no FinQA, com modelos abertos de cerca de 8B e sem ajuste fino. A pergunta de pesquisa é: em perguntas numéricas sobre relatórios financeiros, como a forma de apresentar a tabela ao LLM afeta a acurácia e o custo em tokens, e como esse efeito muda com a complexidade do raciocínio?

Hipóteses. Cada uma decorre de uma lacuna:

1. H1 (L1, L2): o formato altera a acurácia de modelos de ~8B no FinQA, e o melhor formato pode variar entre modelos, como varia nos estudos de formato.
2. H2 (L3): selecionar as linhas relevantes reduz tokens sem perder acurácia quando a seleção preserva os operandos, e perde acurácia quando os corta, como no resultado do Dater em finanças.
3. H3 (L4, L5): as diferenças entre representações crescem nas perguntas de mais passos e nas que exigem tabela e texto.

Desenho. Usamos o conjunto de teste oficial do FinQA (1.147 perguntas) e três modelos abertos: Llama 3.1 8B, Qwen3-8B e Phi-4-mini. Comparamos quatro representações da tabela, mantendo o texto do relatório igual em todas:

- Markdown, o formato mais usado em pipelines de RAG e o adotado pelo TAT-LLM;
- JSON, o formato que lidera em Singha et al. e serve de referência nos estudos de custo (TOON, JTON);
- Linearizada, em que cada valor vira uma frase com seus cabeçalhos de linha e coluna, na linha do template do FinQA e da serialização por célula do MT2Net;
- Seletiva, com o cabeçalho e apenas as linhas relevantes para a pergunta, escolhidas sem usar o gabarito, no estilo do Dater e do TAP4LLM.

A condição seletiva usa o mesmo formato da Markdown, para que a comparação entre as duas isole o efeito da seleção (L3). Como diagnóstico, uma versão com as linhas do gabarito mede o teto da seleção, como o FinQANet-Gold fez para modelos treinados.

Controles. Fixamos prompt, posição da pergunta e exemplos (retirados do treino), já que Sui et al. mostram que essas variáveis podem pesar mais que o formato. A geração usa temperatura zero e as mesmas versões de modelo e tokenizador em todas as condições.

Medidas. A métrica principal é a acurácia numérica com tolerância de arredondamento, objetiva como a acurácia de execução do FinQA. Para o custo, contamos os tokens de entrada com o tokenizador de cada modelo, incluindo o custo da etapa de seleção, e resumimos o compromisso em acurácia por mil tokens, como no TOON. As diferenças são comparadas em pares, nas mesmas perguntas, com intervalos de confiança por bootstrap, que faltam no TOON e no JTON.

Análise. Separamos os resultados pelo número de passos do programa anotado (1, 2, 3 ou mais), pela origem da evidência (tabela, texto ou ambos) e pelo tamanho da tabela. Nos erros, distinguimos falha de extração de falha de cálculo, seguindo a taxonomia de Srivastava et al., porque o TAT-LLM mostra que erros de conta em modelos pequenos podem mascarar o efeito do formato.

Lacuna	Como a proposta responde
L1 — formato fixo no domínio financeiro	Quatro representações no FinQA, com tudo o mais constante
L2 — rankings sem modelos abertos pequenos	Três modelos de ~8B, com resultados por modelo
L3 — efeito da seleção não isolado	Markdown completo contra Markdown seletivo, mais o teto com o gabarito

Lacuna	Como a proposta responde
L4 — acurácia e custo separados	Tokens por tokenizador, custo da seleção e acurácia por mil tokens
L5 — sem cruzamento com complexidade	Resultados por passos, origem da evidência e tamanho da tabela

Contribuição esperada. O estudo deve mostrar se a escolha da representação, uma decisão barata e sem treino, muda o desempenho de modelos abertos pequenos no QA financeiro, e em que tipo de pergunta. Mesmo sem um formato vencedor, o resultado indica quando cada representação oferece o melhor compromisso entre acurácia e custo. Ele também testa se os achados de formato e de seleção obtidos em tarefas gerais valem para raciocínio numérico.

Escopo. O estudo não treina modelos (alternativa do TAT-LLM) nem usa agentes com acesso por código (alternativa do TableRAG). Os resultados valem para as tabelas pequenas e regulares do FinQA; a generalização para tabelas hierárquicas como as do MultiHiertt fica como trabalho futuro.

Referências

- Ahaidous, K., Aarif, L., Schopplich, J., Tabaa, M., Hachimi, H. (2026). A Comprehensive Empirical Evaluation of Token-Oriented Object Notation (TOON) for Large Language Model Applications. *IEEE Access*, 14, 100968–100986. DOI 10.1109/ACCESS.2026.3707409.
- Chen, S.-A. et al. (2024). TableRAG: Million-Token Table Understanding with Language Models. *NeurIPS 2024*, v. 37.
- Chen, Z. et al. (2021). FinQA: A Dataset of Numerical Reasoning over Financial Data. *EMNLP 2021*, 3697–3711. DOI 10.18653/v1/2021.emnlp-main.300.
- Liu, N. F. et al. (2024). Lost in the Middle: How Language Models Use Long Contexts. *TACL*, 12, 157–173. DOI 10.1162/tacl_a_00638.
- Lu, W., Zhang, J., Fan, J., Fu, Z., Chen, Y., Du, X. (2025). Large Language Model for Table Processing: A Survey. *Frontiers of Computer Science*, 19(2), 192350. DOI 10.1007/s11704-024-40763-6.
- Min, D. et al. (2024). Exploring the Impact of Table-to-Text Methods on Augmenting LLM-based Question Answering with Domain Hybrid Data. *NAACL 2024 (Industry Track)*, 464–482.
- Nandakishore, G. (2026). JTON: A Token-Efficient JSON Superset with Zen Grid Tabular Encoding for Large Language Models. Preprint, arXiv 2604.05865.

- Singha, A., Cambronero, J., Gulwani, S., Le, V., Parnin, C. (2023). Tabular Representation, Noisy Operators, and Impacts on Table Structure Understanding Tasks in LLMs. *NeurIPS 2023 Workshop on Table Representation Learning*.
- Srivastava, P., Malik, M., Gupta, V., Ganu, T., Roth, D. (2024). Evaluating LLMs' Mathematical Reasoning in Financial Document Question Answering. *Findings of ACL 2024*. DOI 10.18653/v1/2024.findings-acl.231.
- Sui, Y., Zhou, M., Zhou, M., Han, S., Zhang, D. (2024). Table Meets LLM: Can Large Language Models Understand Structured Table Data? A Benchmark and Empirical Study. *WSDM 2024*. DOI 10.1145/3616855.3635752.
- Sui, Y. et al. (2024). TAP4LLM: Table Provider on Sampling, Augmenting, and Packing Semi-structured Data for Large Language Model Reasoning. *Findings of EMNLP 2024*.
- Ye, Y., Hui, B., Yang, M., Li, B., Huang, F., Li, Y. (2023). Large Language Models are Versatile Decomposers: Decomposing Evidence and Questions for Table-based Reasoning. *SIGIR 2023*. DOI 10.1145/3539618.3591708.
- Zhao, Y., Li, Y., Li, C., Zhang, R. (2022). MultiHiertt: Numerical Reasoning over Multi Hierarchical Tabular and Textual Data. *ACL 2022*, 6588–6600. DOI 10.18653/v1/2022.acl-long.454.
- Zhu, F. et al. (2021). TAT-QA: A Question Answering Benchmark on a Hybrid of Tabular and Textual Content in Finance. *ACL-IJCNLP 2021*, 3277–3287. DOI 10.18653/v1/2021.acl-long.254.
- Zhu, F., Liu, Z., Feng, F., Wang, C., Li, M., Chua, T.-S. (2024). TAT-LLM: A Specialized Language Model for Discrete Reasoning over Tabular and Textual Data. *ICAIF 2024*. arXiv 2401.13223.